

1473 TB 压缩到 1.1 TB： 破解大规模全基因组数据管理难题

Cell Genomics 最新研究：vcf2agds + STAARpipeline
为英国生物银行 50 万人全基因组测序数据管理提供全新解决方案

Cell Genomics • 2025

发布时间：2025年12月

想象一下：50 万人的全基因组测序数据，存储在超过 15 万个文件中，总体积高达 1473 太字节——这相当于约 150 万张 DVD 的容量。如何让全球研究者能够高效管理和分析这些数据，成为精准医学时代最紧迫的挑战之一。

1 背景：数据洪流下的困境

过去十年，全基因组测序（WGS）技术飞速发展，催生了以英国生物银行（UK Biobank）、美国 TOPMed 和 All of Us 计划为代表的超大规模基因组研究项目。



英国生物银行于 2023 年 11 月发布的 50 万人全基因组 VCF 数据，被拆分为 151,561 个文件块，总体积高达 **1473.85 TiB**，平均每个文件约 9.96 GiB。如此庞大的数据体量，给下游分析带来了极大挑战——存储成本高昂、传输效率低下、分析流程复杂，严重制约了科学研究的推进速度。

2 创新方案：aGDS 格式与 vcf2agds 工具包

近日，发表于 *Cell Genomics* 的研究提出了一套端到端的解决方案，核心是 **注释基因组数据结构（aGDS）格式**与配套工具包 **vcf2agds**。

核心突破

aGDS 格式在保留全部基因组与功能注释信息的同时，将 UK Biobank 50 万人 WGS 数据从 **1473.85 TiB** 压缩至仅 **1.10 TiB**，实现了约 **1336 倍** 的惊人压缩比，同时生成按染色体组织的 **23 个文件**，极大简化了数据管理结构。



3 完整分析流程：从原始数据到关联发现

vcf2agds 工具包构建了一套基于云平台（UK Biobank RAP）的完整 WGS 分析 workflow，主要包含以下步骤：

- **数据准备**
整合基因型、表型及协变量数据，作为分析输入
- **格式转换（vcf2agds 核心）**
通过 vcf_trimmer、vcf_merger、vcf2gds 三个子工具，将 VCF 格式高效转换为 GDS 格式，一次转换，支持所有下游分析复用
- **变异功能注释（FAVORannotator）**
对全基因组所有变异进行多维度功能注释，生成 aGDS 文件，集成基因组与功能信息于一体
- **群体结构与亲缘关系推断**
使用 FastSparseGRM 计算祖先主成分（PCs）与稀疏遗传关系矩阵（GRM），校正混杂因素
- **功能知情关联分析（STAARpipeline）**
结合功能注释信息，对常见及罕见编码/非编码变异进行全基因组关联分析

4 应用验证：总胆固醇关联分析

研究团队以总胆固醇（Total Cholesterol）为表型，利用 STAARpipeline 对 UK Biobank 50 万人 WGS 数据进行了功能知情罕见变异关联分析，验证了该工具链的实际效能。

分析结果亮点

- 共检测到 **480 个** 全基因组显著水平的编码及非编码关联信号
- 同时覆盖 **常见变异**（Common Variants）与 **罕见变异**（Rare Variants）分析
- 整合多类别功能注释信息，实现 **功能知情（Functionally Informed）** 的精准关联检测
- 支持基因中心分析与非基因中心分析，涵盖编码区与非编码区功能类别
- 可在云平台上实现 **可扩展、可重复** 的大规模分析部署

"vcf2agds 提供了一套流线性解决方案，用于将 VCF 文件转换为 aGDS 格式，使数十万样本的生物银行规模 WGS 数据的高效管理与分析成为可能。"

—— 原文摘要，Cell Genomics, 2025

5 为什么这项研究重要？

- **存储革命**
1336 倍压缩比大幅降低数据存储成本，让更多机构具备分析能力
- **效率提升**
从 15 万文件块精简至 23 个染色体文件，显著降低 I/O 复杂度
- **数据整合**
将基因型与功能注释无缝集成于单一文件，告别多文件拼接痛苦
- **推动精准医学**
为罕见病、复杂疾病的遗传机制研究提供可扩展的数据基础设施

值得一提的是，vcf2agds 具备高度的**灵活性与兼容性**——研究团队同时完成了对 UK Biobank GraphTyper 500k WGS 数据集和 ML 校正 DRAGEN 500k WGS 数据集的转换，充分验证了工具在不同 WGS 调用策略下的通用性。

论文作者

Xihao Li, Andrew R. Wood, Yuxin Yuan, Manrui Zhang, Yushu Huang, Gareth Hawkes, Robin N. Beaumont, Michael N. Weedon, Wenyan Li, Xiaoyu Li, Xihong Lin, Zilin Li
哈佛大学、浙江大学、东北师范大学、英国埃克塞特大学等

- #全基因组测序
- #英国生物银行
- #数据格式
- #罕见变异分析
- #STAARpipeline
- #精准医学
- #Cell Genomics