

UK Biobank大规模遗传分析 核心软件工具全景解析

PLINK / PLINK2 / REGENIE / BOLT-LMM / PHESANT / SAIGE / SAIGE-GENE+ 七大工具深度对比

01 背景：UK Biobank带来的挑战与机遇

UK Biobank (UKB) 是目前全球规模最大的人群队列之一，汇集了约50万英国参与者的基因组数据、电子健康记录、影像学资料及问卷信息。其宏大的数据规模，一方面为全基因组关联分析（GWAS）提供了前所未有的统计检验力，另一方面也对分析软件的计算效率、统计模型及表型处理方法提出了极高的要求。

UK Biobank包含 ~50万 受试者、~800万 基因型变异位点及 数千个 表现型，传统逐位点、逐表型的分析策略已难以满足其规模需求，亟需更高效的统计与软件解决方案。

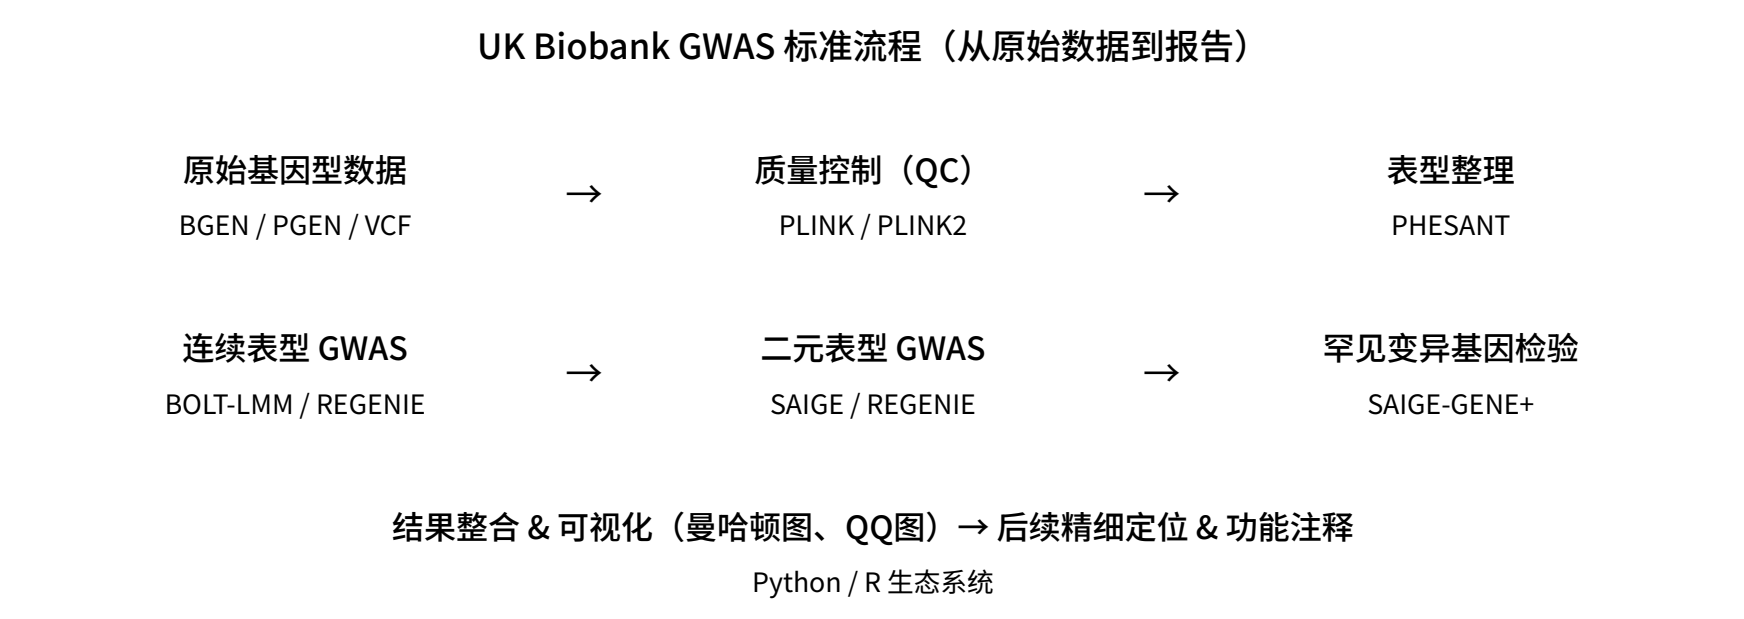
50万+	800万+	数千个
参与者样本量	基因型变异位点	表现型特征

02 七大核心软件：功能与定位

在UKB相关研究中，以下七款软件承担着从质控、关联分析到表型处理的不同关键角色。

PLINK v1.07 / 经典版 遗传流行病学领域的“瑞士军刀”，提供全面的质控（QC）、连锁不平衡（LD）计算、家系分析及基本关联检验功能，是入门GWAS的标配工具。 质控 & 基础GWAS	PLINK2 高性能升级版 PLINK的现代化重构版本，采用多线程及SIMD指令集加速，支持PGEN格式压缩存储，在UKB规模数据上比PLINK1快约10–100倍，同时支持广义线性模型。 高效 & GLM
REGENIE 全基因组回归分析 采用分块脊回归（ridge regression）策略，将混合线性模型的计算复杂度降至近似线性，可在数天内完成UKB百万级变异全表型扫描，内存需求极低。 超大规模 & 低内存	BOLT-LMM 线性混合模型 利用共轭梯度法和随机化算法高效求解线性混合模型，在控制群体分层和亲缘关系同时显著提升统计检验力，是UKB连续型表型GWAS的主流选择之一。 LMM & 连续表型
PHESANT 表型扫描工具 专为UKB表型数据设计的自动化分析流水线，可根据数据类型自动选择线性回归、logistic回归或有序logistic回归，一键完成数千个UKB表现型的系统扫描（PheWAS）。 PheWAS & 自动化	SAIGE 稀有变异 & 二元表型 针对案例-对照严重不平衡（如1:1000）问题，引入鞍点近似（SPA）校正logistic混合模型的I类错误膨胀，尤其适合UKB电子病历（EHR）衍生的二元表型分析。 SPA & 不平衡表型
SAIGE-GENE+ 升级版 （原SAIGE-GENE，基因层面聚合检验） 在SAIGE框架上扩展至基因/区域水平的聚合检验（burden test、SKAT、SKAT-O），整合多种注释权重，对超低频及罕见变异进行基因聚合关联分析，是UKB外显子组测序稀有变异研究的核心工具。 基因聚合 & 罕见变异	

03 典型分析流程



04 关键方法对比

软件	统计模型	适用表型	UKB规模可行性	核心优势
PLINK	线性/logistic回归	连续 & 二元	✓ 质控环节	功能全面，社区成熟
PLINK2	GLM（多线程）	连续 & 二元	✓✓ 快速	速度提升10–100×
REGENIE	分块脊回归+LMM	连续 & 二元	✓✓✓ 最优	超低内存，全表型扫描
BOLT-LMM	LMM（随机化算法）	连续	✓✓ 较优	检验力强，广泛验证
PHESANT	自动回归选择	全表型	✓✓ 批量	PheWAS自动化流水线
SAIGE	logistic LMM + SPA	二元（不平衡）	✓✓ 较优	解决case/control失衡
SAIGE-GENE+	聚合检验（SPA）	二元 & 连续	✓✓ 外显子	罕见变异基因级检验

05 在UK Biobank中的实际应用案例

- BOLT-LMM × UKB 连续表型全景扫描**
Loh等（2018）利用BOLT-LMM对UKB约40万样本的数百个连续表型（BMI、血压、血脂等）进行GWAS，在控制亲缘关系的同时识别出大量新型遗传关联位点，成为LMM在大型生物银行应用的里程碑式工作。
- PHESANT × ICD-10疾病表型批量挖掘**
Millard等开发PHESANT并将其直接应用于UKB，自动对1,000余个表型进行回归类型分配与分析，产出表型-遗传变异关联图谱，极大降低了PheWAS的人工操作成本。
- REGENIE × UKB 50万样本全表型GWAS**
Mbatchou等（Nature Genetics, 2021）以UKB全量数据验证REGENIE，在仅约28GB内存的单台服务器上完成约800个表型的全基因组扫描，证明了其在生物银行规模研究中的工业级可行性。
- SAIGE × EHR二元表型**
Zhou等开发SAIGE并以UKB中多种疾病表型（2型糖尿病、哮喘等）进行验证，证明SPA校正有效消除了严重case/control失衡下的I类错误膨胀，使EHR衍生的表型GWAS成为可能。
- SAIGE-GENE+ × UKB外显子组稀有变异**
基于UKB约50万人的外显子组测序数据，SAIGE-GENE+整合burden、SKAT、SKAT-O聚合检验并引入注释权重，系统鉴定多个基因与复杂疾病（如心血管疾病、肥胖相关表型）的罕见变异关联，推动了从常见变异到罕见变异研究的范式转变。

06 如何选择合适的工具？

在实际研究设计中，软件选择应综合考量表型类型、样本量、计算资源及科学问题。以下是简明决策指引：

- 数据质控与预处理**
首选 **PLINK / PLINK2**：MAF过滤、缺失率控制、Hardy-Weinberg过滤、亲缘关系检测（IBD/KING）、主成分分析（PCA）。
- 连续表型GWAS（如身高、BMI、血压）**
BOLT-LMM 或 **REGENIE** 均可；REGENIE在内存受限场景下更友好，BOLT-LMM在中等规模样本下检验力略占优。
- 二元表型GWAS（尤其是不平衡case/control）**
SAIGE 或 **REGENIE**（内置SPA校正）；若表型数量多，REGENIE的批量模式效率更高。
- 大规模多表型扫描（PheWAS）**
PHESANT 用于自动化表型分类与分析流水线搭建；结合 **REGENIE** 完成底层关联计算。
- 外显子组/序列数据稀有变异分析**
SAIGE-GENE+ 是当前最主流的选择，支持多种聚合检验策略及注释驱动的权重方案。

总结展望

随着UK Biobank外显子组测序数据（~50万人）和未来全基因组深度测序数据的开放，基因组分析的计算挑战将进一步升级。PLINK/PLINK2奠定了质控与基础分析的基石；BOLT-LMM与REGENIE将LMM推广至生物银行规模；PHESANT实现了表型批量处理的自动化；SAIGE与SAIGE-GENE+则将混合模型延伸至二元及稀有变异领域。七大工具相互协作、优势互补，共同构成了当今人群遗传流行病学研究的核心软件生态，推动人类对遗传结构与复杂疾病的认知不断深化。